

Чувствительность рекомендательных алгоритмов к коллаборативным и контентным сигналам на датасете VK-LSVD

Сравнительное исследование CF-базлайнов и контент-обогащённого ранжирования

Автор: Мейзлер Лия · VK Education · Рекомендательные системы

Аннотация

Мы исследуем, какой прирост качества ранжирования даёт добавление контентных сигналов поверх коллаборативной фильтрации (CF) на индустриальном датасете коротких видео VK-LSVD. На срезе из 1 500 пользователей и 11 522 видео мы сравниваем три CF-базлайна (ALS, ItemKNN, UserKNN) с контент-обогащёнными вариантами, используя нативные 64-мерные контентные эмбединги датасета. В протоколе полного ранжирования с временным сплитом сильнейшим одиночным методом оказывается ALS ($\text{NDCG@10} = 0.0092$). Позднее слияние (late fusion) контента в ALS не даёт статистически значимого прироста на «тёплом» каталоге ($\Delta\text{NDCG@10} = +0.0002$, $p = 0.59$, парный бутстрап), а контент по отдельности значимо слабее ($p < 0.001$). Развёртка по размерности показывает, что контентный сигнал насыщается уже на 8 из 64 компонент. Однако на отложенном пуле «холодных» айтемов, где у CF нет сигнала, контент почти удваивает HitRate@10 (0.0328 против 0.0171). Вывод: контентные эмбединги не улучшают ранжирование тёплого каталога на плотных данных, но являются решающим сигналом для cold-start; их следует применять как fallback для холодных и «хвостовых» айтемов, а не как глобальный re-ранкер.

1. Введение

Рекомендации коротких видео строятся преимущественно на неявной обратной связи: пользователь за сессию просматривает десятки клипов, порождая плотный временной сигнал. Классический подход — коллаборативная фильтрация, которая моделирует ко-встречаемость взаимодействий и игнорирует содержание айтема. Естественный вопрос: даёт ли добавление контентной информации (эмбедингов видео) измеримый прирост, и если да — где именно.

Мы формулируем задачу как изоляцию «контентного выигрыша» (content gain). CF-базлайн по построению не видит метаданные айтема, поэтому любой прирост при добавлении эмбедингов относится именно к контенту. Мы намеренно используем позднее слияние (взвешенная сумма нормированных скоров), а не конкатенацию признаков: это сохраняет интерпретируемость вклада каждого сигнала и не даёт модели переобучиться на объединённом пространстве.

Важное отличие от исходного плана. VK-LSVD предоставляет единый контентный эмбединг айтема (обученный на видео/описании/аудио сразу), а не отдельные текстовые и визуальные векторы; сырых заголовков и кадров в датасете нет — все идентификаторы анонимизированы. Поэтому классическое сравнение «текст против изображения против мультимодальности» на реальных данных невыполнимо. Мы заменяем эту ось на нативное для датасета свойство: компоненты эмбединга упорядочены, и скалярное произведение первых n компонент приближает косинус полного вектора. Это позволяет варьировать размерность эмбединга (8/16/32/64) как управляемую «силу контентного сигнала».

2. Данные

VK-LSVD — крупнейший открытый индустриальный датасет рекомендаций коротких видео: около 40 млрд взаимодействий, 10 млн пользователей и ~20 млн видео за шесть последовательных месяцев, с глобальным временным упорядочением и нативными

контентными эмбедами. Полный датасет (~452 ГБ) локально необработаем, поэтому эксперименты выполнены на предоставленной подвыборке `up0.001_ip0.001` (плотный срез популярных айтемов), дополнительно урезанной по пользователям для воспроизводимости на одной машине.

Итоговый срез: **1 500 пользователей, 11 522 видео, 152 660 положительных обучающих взаимодействий, 1 453 валидационных пользователей.** Разметка вовлечённости (положительный класс): лайк, репост, сохранение, переход к автору либо просмотр не менее 70% длительности ($\text{timespent} / \text{duration} \geq 0.7$). Такой сигнал отражает специфику формата: явные реакции редки (~1% лайков), а основным сигналом служит время просмотра.

3. Методы

3.1 Коллаборативные базлайны

ALS — матричная факторизация для неявной обратной связи (`implicit`, 64 фактора, регуляризация 0.05, 25 итераций). `ItemKNN` — рекомендатель на косинусной близости айтемов по матрице взаимодействий (`implicit CosineRecommender`, $K = 200$). `UserKNN` — предсказание по `top-100` ближайшим пользователям в косинусной метрике. Все модели обучаются на одной бинарной матрице «пользователь × айтем».

3.2 Контент и позднее слияние

Контентный профиль пользователя — среднее эмбедингов айтемов, с которыми он взаимодействовал в обучении. Контентный скор пары равен скалярному произведению профиля и эмбединга айтема (по первым d компонентам). Итоговый скор слияния: $\text{Pred}(u,i) = z(\text{ALS}(u,i)) + \alpha \cdot z(\text{Content}(u,i))$, где $z(\cdot)$ — построчная (по пользователю) стандартизация скоров для приведения к сопоставимому масштабу. Вес α подбирается по сетке [0.1, 0.5, 1.0], размерность d — по {8, 16, 32, 64}.

3.3 Cold-start эксперимент

Чтобы измерить пользу контента там, где у CF нет сигнала, мы случайно исключаем 15% айтемов из обучения ALS (их факторы становятся неинформативными) и оцениваем ранжирование внутри этого «холодного» пула. Контентная модель использует эмбединги, доступные для всех айтемов, включая холодные.

4. Постановка эксперимента

Обучение — на `train`-неделях, оценка — на валидационной неделе (глобальный временной сплит датасета). Валидационные пользователи разбиты на подвыборку подбора (30%, $n = 435$) и оценки (70%, $n = 1018$): гиперпараметры α и d выбираются на первой, все итоговые метрики отчитываются на второй. Протокол — полное ранжирование по всему каталогу с исключением уже виденных в обучении айтемов. Метрики: `HitRate@1`, `HitRate@10`, `NDCG@10`, `Coverage@10`. Значимость различий проверяется парным бутстрапом по пользователям (1000 ресэмплов, 95% ДИ, двусторонний p).

5. Результаты

5.1 Основное сравнение

ALS — сильнейший одиночный метод по всем метрикам, кроме HitRate@1, где его слегка превосходит слияние. ItemKNN и UserKNN стабильно, но незначимо уступают ALS. Контент по отдельности резко слабее: он не способен ранжировать тёплый каталог.

Модель	HitRate@1	HitRate@10	NDCG@10	Coverage@10
ALS (CF only)	0.0069	0.0815	0.0092	0.0426
ItemKNN	0.0029	0.0747	0.0082	0.0175
UserKNN	0.0059	0.0766	0.0086	0.0160
Content only	0.0010	0.0128	0.0015	0.0151
ALS+Content ($\alpha=0.5$, $d=8$)	0.0079	0.0796	0.0094	0.0430




Рис. 1. Сравнение моделей по четырём метрикам (значения нормированы на максимум по каждой оси).

5.2 Вес слияния и размерность контента

Кривая по α плоская и почти не отклоняется от ALS-базлайна: лучший $\alpha = 0.5$ даёт лишь маргинальное изменение NDCG@10. Развёртка по размерности показывает насыщение сигнала: качество на 8 компонентах не хуже, чем на полных 64, — «толстый» эмбединг избыточен для этой задачи.




Рис. 2. Зависимость NDCG@10 (тест) от веса слияния α . Пунктир — ALS-базлайн.




Рис. 3. Зависимость NDCG@10 (тест) от размерности контентного эмбединга. Пунктир — ALS-базлайн.

dim	HitRate@10	NDCG@10	Coverage@10
8	0.0796	0.0094	0.0430
16	0.0786	0.0093	0.0430
32	0.0796	0.0094	0.0432
64	0.0796	0.0093	0.0432




Рис. 4. Распределение предсказанных скоров: ALS, контент и слияние.

5.3 Статистическая значимость

Парный бутстрап подтверждает: ни один вариант не отличается от ALS значимо, кроме контента-по-отдельности, который значимо хуже. Прирост от слияния статистически неотличим от нуля.

Сравнение (по NDCG@10)	Δ	95% ДИ	p	Значимо
ItemKNN vs ALS	-0.0010	[-0.0038, 0.0023]	0.526	нет
UserKNN vs ALS	-0.0006	[-0.0033, 0.0020]	0.674	нет
Content only vs ALS	-0.0076	[-0.0099, -0.0055]	0.000	да
ALS+Content ($\alpha=0.5$, $d=8$) vs ALS	+0.0002	[-0.0006, 0.0012]	0.594	нет

5.4 Cold-start

Ключевой результат. На отложенном пуле холодных айтемов картина инвертируется: ALS почти не отличим от случайного (у него нет факторов для этих айтемов), тогда как контент почти удваивает HitRate@10. Слияние здесь полностью наследует поведение контента.

Модель (холодный пул, n=702)	HitRate@10	NDCG@10
ALS (CF only)	0.0171	0.0052
Content only	0.0328	0.0103
ALS+Content	0.0328	0.0103




Рис. 5. Ранжирование 15% отложенных (холодных) айтемов: контент — единственный полезный сигнал.

6. Обсуждение

Результаты согласованно указывают на разделение ролей сигналов по режиму данных. На плотном срезе тёплого каталога коллаборативный сигнал уже близок к насыщению: встречаемость взаимодействий содержит почти всю доступную информацию, и добавление контента её дублирует, а не дополняет — отсюда нулевой прирост слияния и плоская кривая по α . Насыщение по размерности ($8 \approx 64$) говорит о том, что для этой задачи достаточно грубой контентной близости; хранить и умножать полные 64-мерные векторы нет смысла.

Противоположная картина в cold-start объясняет, зачем контент вообще нужен: как только у айтема нет истории взаимодействий, CF теряет сигнал полностью, а контентный эмбединг остаётся единственным способом связать новый айтем с интересами пользователя. Именно здесь контент даёт кратный, а не маргинальный выигрыш.

7. Заключение и рекомендация для продакшена

Для продакшена VK рекомендуется применять контентные эмбединги как cold-start / long-tail сигнал, а не как глобальный ре-ранкер. На тёплом каталоге основным ранжировщиком должен оставаться ALS (контентное слияние не окупает вычислительных затрат и не даёт значимого прироста). Контентную ветвь целесообразно включать для айтемов с недостаточной историей — там она кратно повышает попадание в топ. Достаточно первых ~8 компонент эмбединга, что снижает стоимость хранения и инференса контентной ветви.

8. Ограничения

Выводы получены на одном плотном срезе VK-LSVD; на разреженных или преимущественно «хвостовых» распределениях баланс может смещаться в пользу контента и на тёплом каталоге. Подбор гиперпараметров выполнен на валидации (отдельного теста в подвыборке не было), что смягчено внутренним сплитом подбор/оценка. Мы не моделируем последовательность взаимодействий (sequential recommendation), где контент может играть иную роль. Наконец, эмбединги предвычислены и унифицированы по модальностям — отдельный вклад текста и изображения на этих данных измерить нельзя.

9. Воспроизводимость

Пайплайн реализован в едином Jupyter-ноутбуке в функциональном стиле (загрузка → разметка → CF-модели → контентное слияние → cold-start → бутстрап → фигуры). Все таблицы сохраняются в CSV, графики — в PNG. Порядок запуска и сборка PDF-отчёта описаны в README проекта.

Литература

- [1] Poslavsky A. и др. VK-LSVD: A Large-Scale Industrial Dataset for Short-Video Recommendation. Proceedings of the ACM Web Conference 2026 (WWW '26).
- [2] Hu Y., Koren Y., Volinsky C. Collaborative Filtering for Implicit Feedback Datasets. ICDM 2008.
- [3] Frederickson B. implicit: Fast Collaborative Filtering for Implicit Feedback Datasets. Программная библиотека, 2016–.